

# Apprentissage statistique : modélisation décisionnelle et apprentissage profond (RCP209)

Perspectives de l'apprentissage profond

Nicolas Audebert

`nicolas.audebert@lecnam.net`

`http://cedric.cnam.fr/vertigo/Cours/ml2/`

Département Informatique  
Conservatoire National des Arts & Métiers, Paris, France

7 juin 2023

# Plan du cours

1 Apprentissage profond non-supervisé

2 Robustesse et explicabilité

3 Théorie

# Apprentissage non-supervisé

## Apprentissage supervisé

Dans le cadre de l'apprentissage supervisé, on cherche à construire un modèle  $p_{\theta}(y|X)$  :

- $\mathcal{D} = (\mathbf{X}, \mathbf{y})$  jeu d'entraînement avec  $\mathbf{X}$  les observations et  $\mathbf{y}$  les étiquettes de supervision,
- $\theta$  paramètres d'un modèle dans une famille paramétrique  $\mathcal{F} : \mathcal{X} \rightarrow \mathcal{Y}$
- ⊖ difficulté d'accès aux annotations (expertise, coût)
- ⊖ annotations complexes pour certaines tâches (par ex., quelle image est similaire à quelle autre ?)

## Apprentissage non-supervisé

Que faire si la supervision  $\mathbf{y}$  n'est pas disponible ou inconnue ?

- Définir une fonction de coût qui ne dépend que des observations  $\mathbf{X}$  !

# Auto-encodeurs

## Architecture auto-encodeur

Pour un jeu de données  $\mathcal{X} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$  de dimension  $d$  :


- Encodeur :  $\mathcal{E} : \mathbb{R}^d \rightarrow \mathbb{R}^p \implies$  projette les observations dans un espace de dimension inférieure ( $p \ll d$ )
- Décodeur :  $\mathcal{D} : \mathbb{R}^p \rightarrow \mathbb{R}^d \implies$  retransforme les activations intermédiaires en observations

Fonction objectif à optimiser : erreur de construction (par ex., MSE ou vraisemblance)

Exemple : auto-encodeur le plus simple  
(MLP à une seule couche cachée)

$$\mathbf{z} = \mathcal{E}(\mathbf{W}\mathbf{x} + \mathbf{b}) , \quad \hat{\mathbf{x}} = \mathcal{D}(\mathbf{W}^t\mathbf{z} + \mathbf{b}^t)$$

$$\mathcal{L} = \sum_{i=1}^N \|\mathbf{x}_i - \hat{\mathbf{x}}\|^2$$



# Intérêt des auto-encodeurs

## Espace latent

- Apprentissage d'une représentation latente de dimensionnalité plus faible (*deep features*)
- Apprentissage par transfert :
  - Entraînement non-supervisé sur une grande masse de données
  - Fine-tuning sur un petit nombre d'exemples supervisés

# Apprentissage non-supervisé ou auto-supervisé

- Le succès de l'apprentissage profond s'est initialement concentré sur des tâches supervisées, comme la classification.
- Mais pas de succès équivalent en apprentissage non-supervisé avec les auto-encodeurs !
  - ⇒ classification : lien direct entre la fonction objectif (entropie croisée) et les métriques d'évaluation
  - ⇒ reconstruction : lien discutable avec les applications finales
    - Si la reconstruction apprend bien les données, est-ce que le modèle généralisera bien à des nouvelles observations ?
    - La reconstruction conserve 100% de l'information, ce n'est pas nécessaire ni souhaitable dans la plupart des cas.
- Représentations profondes  $\Leftrightarrow$  représentations plus abstraites  $\Leftrightarrow$  invariance et généralisation  $\Leftrightarrow$  perte d'information


## Objectifs en apprentissage non-supervisé

- 1 Définir une fonction de coût sans reconstruction
- 2 Reformuler des problèmes non-supervisés en problèmes supervisés

# Word2Vec MIKOLOV et al. 2013

- *Word embeddings* : chaque mot encodé en *one-hot*  $\in \mathbb{R}^V$  a vector  $\in \mathbb{R}^d$
- Principe : prédire un mot à partir de son contexte (mots voisins)
  - Hypothèse : des mots similaires apparaissent dans des contextes similaires
  - Entrée : sac de mots du contexte
  - Projection dans un espace de plus petite dimension (MLP), softmax pour la classification du mot central


⇒ pas de supervision humaine




# Tâches prétextes

## Créer sa propre supervision

- Pas d'étiquette, tâche de reconstruction peu adaptée  $\Rightarrow$  quelle supervision utiliser ?
- $\sim$  augmentation de données : créer ses propres tâches en fonction de l'a priori sur les données




RotNet : générer des variantes tournées des images, prédire l'angle de rotation GIDARIS, SINGH et KOMODAKIS 2018



Jigsaw : (a) découper une image en morceaux, (b) les mélanger, (c) apprendre à reconstruire les positions des morceaux MISRA et FAMILY=MAATEN 2020

$\rightarrow$  cf. travaux pratiques

# Apprentissage contrastif



SimCLR CHEN et al. 2020

## Principe général

Rapprocher des observations similaires,  
éloigner des observations différentes

- Générer différentes vues  $\tilde{x}_i$  d'une même observation  $x_i$  (ex. :  $\neq$  augmentations d'une image)
- Rapprocher les *features* des vues d'une même observations

$$\min_{\theta} \|x_i - \tilde{x}_i\|$$

- Éloigner les *features* d'observations différentes

$$\max_{\theta} \|x_i - x_j\|$$


# Apprentissage semi-supervisé

## Cadre formel

Dans l'apprentissage semi-supervisé, le jeu de données  $\mathcal{D}$  est divisé en deux ensembles :

- les données annotées :  $\mathcal{D}_{\text{labeled}} = \{(\mathbf{x}_1^*, \mathbf{y}_1), \dots, (\mathbf{x}_n^*, \mathbf{y}_n)\}$
- les données non-annotées :  $\mathcal{D}_{\text{unlabeled}} = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$

Généralement,  $n \ll N$  (les données annotées sont peu nombreuses par rapport aux non-annotées).



HybridNet : séparation de l'information discriminante pour la classification et information utile à la reconstruction dans deux branches ROBERT, THOME et CORD 2018

# Plan du cours

1 Apprentissage profond non-supervisé

2 Robustesse et explicabilité

3 Théorie

# Explicabilité et interprétabilité

## Explicabilité

Capacité d'expliquer en termes humainement compréhensibles les raisons pour lesquelles une prédiction est émise.

## Interprétabilité

Propriété intrinsèque d'un modèle à la transparence pour la prise de décision.

Exemple : arbres de décision.


- Important pour les systèmes critiques : certification, compréhension des erreurs
- Motivations légales : responsabilité en cas de panne ? Confidentialité des données ? Biais discriminatoires ?
- Aide à la compréhension, à l'acceptation humaine et au debug

## Approches pour l'interprétabilité/explicabilité


- **Visualisation** : pour les données observables et interprétables (textes, sons, images)

⇒ généralement *post-hoc* (après entraînement du modèle, sans modification)

- **Distillation** : approximer un modèle non-interprétable par un modèle interprétable
- **Intrinsèque** : utiliser un modèle interprétable par construction



# CAM/GradCAM



SELVARAJU et al. 2017

- Permet d'obtenir des cartes de chaleur des pixels qui contribuent à la prise de décision
- Se base sur la norme des gradients de la dernière couche pour identifier les régions "chaudes"

# Attaques adverses

## Régularité des frontières de décision

Entrée en grande dimension + grand nombre de paramètres  $\implies$  frontière de décision irrégulière  $\Rightarrow$  possibilité de créer des perturbations invisibles qui changent la prédiction !

## Exemple d'attaque adverse en boîte blanche

*Fast Gradient Sign Attack* (GOODFELLOW, SHLENS et SZEGEDY 2015) sur un modèle  $\theta$  :


$$\bar{\mathbf{x}} = \mathbf{x} + \epsilon \text{signe}(\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}, \mathbf{y}; \theta))$$

- Pour une observation  $\mathbf{x}$  dont on veut changer la classe  $\mathbf{y}$
- Calculer **une montée de gradient** par rapport à  $\mathbf{x}$
- Appliquer un déplacement de **norme minimale  $\epsilon$**  dans la direction du gradient



$\mathbf{x}$   
"panda"  
57.7% confidence

+ .007  $\times$



$\text{sign}(\nabla_{\mathbf{x}} J(\theta, \mathbf{x}, \mathbf{y}))$   
"nematode"  
8.2% confidence


=



$\mathbf{x} + \epsilon \text{sign}(\nabla_{\mathbf{x}} J(\theta, \mathbf{x}, \mathbf{y}))$   
"gibbon"  
99.3 % confidence

# Robustesse

- Les modèles profonds ne sont pas nécessairement robustes aux variations dans l'espace d'entrée
- Cas notable : les exemples adversaires



# Incertitude


L'activation *softmax* dans les réseaux profonds n'est **pas** calibrée :

- un classifieur qui indique  $p = 90\%$  pour la classe "Chien" n'a en généralement pas raison 9 fois sur 10 !
- le vecteur de probabilité produit par un softmax n'est pas une mesure de confiance (ou d'incertitude)
- Prédiction incorrecte  $\leftrightarrow$  confiance élevée injustifiée  
 $\Rightarrow$  problématique pour des domaines critiques

Solutions : *Bayesian Dropout* GAL et GHARAMANI 2015, calibration sur le jeu de validation, etc.

## Jeux de données et biais

- Beaucoup de jeux de données sont disponibles + capacité industrielle à en produire de nouveaux
- Mais attention aux biais d'échantillonnage et d'annotation !
  - Exemple : jeu de données VQA 1.0
  - Question : "*What sport is represented ?*" → Tennis dans 41% des cas !
- Évaluer des outils tiers sur ses propres jeux de données *représentatifs*
  - Possibilité d'utiliser des données synthétiques dans certains cas



<http://gendershades.org>


# Plan du cours

1 Apprentissage profond non-supervisé

2 Robustesse et explicabilité


3 Théorie

# Théorie de l'apprentissage profond



## Pourquoi l'apprentissage profond fonctionne aussi bien ?

- Empiriquement, les résultats de l'apprentissage profond sont exceptionnels
- Mais la compréhension théorique des modèles est limitée :
  - Optimisation : comment arrive-t-on à optimiser des problèmes non-convexes en si grande dimension ?
  - Généralisation : pourquoi les modèles profonds souffrent si peu du sur-apprentissage ?



# Optimisation non-convexe

## La faille historique

Historiquement, l'optimisation des réseaux de neurones était perçue comme une impossibilité.

Problème d'optimisation :  $\min_{\theta} \mathcal{L}(\mathbf{X}, \mathbf{y}; \theta)$

avec  $\theta$  un ensemble de paramètres en grande dimension et  $\mathcal{L}$  une fonction objective non-convexe par rapport à  $\theta$ .

⇒ aucune garantie de convergence de la descente de gradient !

- On observe peu de minimum locaux en grande dimension mais beaucoup de points selles DAUPHIN et al. 2014
  - Les solveurs basés gradients parviennent à s'échapper des points selles (GOODFELLOW, VINYALS et SAXE 2015)
- Les minima locaux sont tous "aussi bon" : valeur similaire de  $\mathcal{L}$  (CHOROMANSKA et al. 2015)
- Le minimum global mène de toute façon au sur-apprentissage !
  - On cherche plutôt des (quasi-)minima dans des régions "plates"






FIGURE 2. The landscape of  $\mathcal{L}$ .

# Apprentissage profond et généralisation

- Complexité de Rademacher : capacité d'un modèle à apprendre des étiquettes aléatoires

$$\mathcal{R}_n(\mathcal{H}) = E_{\sigma} \left[ \sup_{h \in \mathcal{H}} \frac{1}{n} \sum_{i=1}^n \sigma_i h(x_i) \right]$$


- Repenser la généralisation pour les réseaux profonds (ZHANG et al. 2017)



- Les modèles profonds apprennent sans problèmes des étiquettes aléatoires  
 $\Rightarrow \mathcal{R}_n(\mathcal{H}) \approx 1 \Rightarrow$  aucune garantie théorique de généralisation
- La théorie classique de l'apprentissage ne suffit pas à expliquer la bonne capacité des modèles profonds à généraliser...

# Généralisation des modèles sur-paramétrisés

- Modèle classique : 2 phases (à jeu de données fixé)
  - 1 Sous-capacité : capacité  $\nearrow$ , généralisation  $\nearrow$
  - 2 Sur-capacité : capacité  $\nearrow$ , généralisation  $\searrow$
- Modèles profonds : courbe en forme de double-U ! (BELKIN et al. 2019)



## “Double descent”

Au-delà d'un certain nombre de paramètres, on observe un régime d'interpolation “sur-paramétrisé” : bonne généralisation, pourtant bien au-delà du régime de sur-apprentissage classique.




Figure 6: Illustration of double descent for Random ReLU networks in one dimension. Left: Classical under-parameterized regime (3 parameters). Middle: Standard over-fitting, slightly above the interpolation threshold (30 parameters). Right: “Modern” heavily over-parameterized regime (3000 parameters).

# Bibliographie I

-  BELKIN, Mikhail et al. (6 août 2019). "Reconciling Modern Machine-Learning Practice and the Classical Bias-Variance Trade-Off". In : *Proceedings of the National Academy of Sciences* 116.32, p. 15849-15854. DOI : 10.1073/pnas.1903070116. URL : <https://www.pnas.org/doi/abs/10.1073/pnas.1903070116> (visité le 06/06/2023).
-  CHEN, Ting et al. (13 juill. 2020). "A Simple Framework for Contrastive Learning of Visual Representations". In : *Proceedings of the 37th International Conference on Machine Learning*. T. 119. ICML'20. JMLR.org, p. 1597-1607.
-  CHOROMANSKA, Anna et al. (21 fév. 2015). "The Loss Surfaces of Multilayer Networks". In : *Proceedings of the Eighteenth International Conference on Artificial Intelligence and Statistics*. Artificial Intelligence and Statistics. PMLR, p. 192-204. URL : <https://proceedings.mlr.press/v38/choromanska15.html> (visité le 06/06/2023).
-  DAUPHIN, Yann N. et al. (8 déc. 2014). "Identifying and Attacking the Saddle Point Problem in High-Dimensional Non-Convex Optimization". In : *Proceedings of the 27th International Conference on Neural Information Processing Systems - Volume 2*. NIPS'14. Cambridge, MA, USA : MIT Press, p. 2933-2941.

## Bibliographie II

-  GAL, Yarin et Zoubin GHAHRAMANI (6 juin 2015). "Dropout as a Bayesian Approximation : Representing Model Uncertainty in Deep Learning". *arXiv* : 1506.02142 [cs, stat]. URL : <http://arxiv.org/abs/1506.02142> (visité le 03/02/2016).
-  GIDARIS, Spyros, Praveer SINGH et Nikos KOMODAKIS (15 fév. 2018). "Unsupervised Representation Learning by Predicting Image Rotations". In : *International Conference on Learning Representations*. (Visité le 09/03/2022).
-  GOODFELLOW, Ian, Jonathon SHLENS et Christian SZEGEDY (2015). "Explaining and Harnessing Adversarial Examples". In : *International Conference on Learning Representations*. URL : <http://arxiv.org/abs/1412.6572>.
-  GOODFELLOW, Ian J., Oriol VINYALS et Andrew M. SAXE (21 mai 2015). *Qualitatively Characterizing Neural Network Optimization Problems*. DOI : 10.48550/arXiv.1412.6544. *arXiv* : 1412.6544 [cs, stat]. URL : <http://arxiv.org/abs/1412.6544> (visité le 06/06/2023). preprint.
-  MIKOLOV, Tomas et al. (16 jan. 2013). "Efficient Estimation of Word Representations in Vector Space". In : *ICLR 2013*. *arXiv* : 1301.3781. URL : <http://arxiv.org/abs/1301.3781> (visité le 26/03/2019).

## Bibliographie III



MISRA, Ishan et prefix=van der useprefix=true FAMILY=MAATEN given=Laurens (juin 2020). "Self-Supervised Learning of Pretext-Invariant Representations". In : *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA : IEEE, p. 6706-6716. ISBN : 978-1-72817-168-5. DOI : 10.1109/CVPR42600.2020.00674. URL : <https://ieeexplore.ieee.org/document/9156540/> (visité le 14/02/2022).



RAS, Gabrielle et al. (25 jan. 2022). "Explainable Deep Learning : A Field Guide for the Uninitiated". In : *Journal of Artificial Intelligence Research* 73, p. 329-396. ISSN : 1076-9757. DOI : 10.1613/jair.1.13200. URL : <https://www.jair.org/index.php/jair/article/view/13200> (visité le 06/06/2023).



ROBERT, Thomas, Nicolas THOME et Matthieu CORD (2018). "HybridNet : Classification and Reconstruction Cooperation for Semi-Supervised Learning". In : *Proceedings of the European Conference on Computer Vision (ECCV)*, p. 153-169. URL : [https://openaccess.thecvf.com/content\\_ECCV\\_2018/html/Thomas\\_Robert\\_HybridNet\\_Classification\\_and\\_ECCV\\_2018\\_paper.html](https://openaccess.thecvf.com/content_ECCV_2018/html/Thomas_Robert_HybridNet_Classification_and_ECCV_2018_paper.html) (visité le 06/06/2023).

## Bibliographie IV



SELVARAJU, Ramprasaath R. et al. (oct. 2017). "Grad-CAM : Visual Explanations from Deep Networks via Gradient-Based Localization". In : *2017 IEEE International Conference on Computer Vision (ICCV)*. 2017 IEEE International Conference on Computer Vision (ICCV), p. 618-626. DOI : 10.1109/ICCV.2017.74.



ZHANG, Chiyuan et al. (2017). "Understanding Deep Learning Requires Rethinking Generalization". In : *International Conference on Learning Representations*. URL : <https://openreview.net/forum?id=Sy8gdB9xx>.